## 数据挖掘作业

数据集选择: Wine Reviews, winemag-data\_first150k.csv 文件包含八个标称属性,分别是 'country', 'description', 'designation', 'province', 'region\_1', 'region\_2', 'variety', 'winery'; winemag-data-130k-v2.csv 文件包含十一个标称属性, 分别是'country', 'description', 'designation', 'province', 'region\_1', 'region\_2', 'taster\_name', 'taster\_twitter\_handle', 'title', 'variety', 'winery'。

## 数据分析过程:

1: 数据预处理

空值处理: 数量少的直接删除, 多的用最大频率替换

2: 找频繁项集

对多个属性进行关联规则 挖掘,需要将来自于不同属性的值转化为可生成频繁项集的形式。采用 Apriori 算法构建频繁项集。在此任 务中,频繁项集是指经常出现在一起的属性项的集合,而一个项集的支持度 (support) 定义为数据集中包含该项集的记录所占的比例。首先,规定最小 支持度 (min-support) 为 0.25,最小置信度 (min-confidence) 为 0.5。

```
def apriori(self, dataset):
    C1 = self.create_C1(dataset)
    dataset = [set(data) for data in dataset]
    L1, support_data = self.scan_D(dataset, C1)
    L = [L1]
    k = 2
    while len(L[k-2]) > 0:
        Ck = self.apriori_gen(L[k-2], k)
        Lk, support_k = self.scan_D(dataset, Ck)
        support_data.update(support_k)
        L.append(Lk)
        k += 1
    return L, support_data
```

## 3: 计算支持度, 置信度, Lift 指标

首先从一个频繁项集开始,创建一个规则列表,其中规则右部只包含一个元素,然后对这些规则计算是否满足最小置信度要求。接下来合并所有的剩余规则列表来创建一个新的规则列表,其中规则右部包含两个元素。最后,对于产生的每个规则,我们分别计算其支持度(support)、置信度(confidence)以及提升度(Lift)指标。

```
def cal_conf(self, freq_set, H, support_data, big_rules_list):
# 评估生成的规则
prunedH = []
for conseq in H:
    sup = support_data[freq_set]
    conf = sup / support_data[freq_set - conseq]
    lift = conf / support_data[freq_set - conseq]
    if conf >= min_confidence:
        big_rules_list.append((freq_set-conseq, conseq, sup, conf, lift))
        prunedH.append(conseq)
return prunedH
```

## 4: 可视化并分析

```
[T.set'] [[Province, "Machington"]], "Aset'; [[Country', 'DD']], "map' : 0.78818664418098, "comf' : 1.0, "11ft' : 1.7881686634170)]
(T.set': [[Travine, "Mirginel Boons"]], "y.set'; [[Country', 'DD']], "map' : 0.7881280240446022, "comf' : 1.0, "11ft' : 3.489718808175980)
(T.set': [[Travine, "Mirginel Boons"]], "y.set'; [[Trovince," (Silfornia]]], "map' : 0.7881280240446022, "comf' : 1.0, "11ft' : 3.489718808175980)
(T.set': [[Travine, "Mirginel Boons"]], "y.set'; [[Trovince," (Silfornia]]], "map' : 0.7881280240446022, "comf' : 1.0, "11ft' : 3.489718808175980)
(T.set': [[Travine, "Mirginel Boons"]], "y.set'; [[Travine, "Mirginel Boons"]], "map' : 0.788128024446022, "comf' : 1.0, "11ft' : 3.489718808175880)
(T.set': [[Travine, "Mirginel Boons"]], "y.set'; [[Travine, "man, "Mirginel Boons"]], "map' : 0.788128024446022, "comf' : 1.0, "11ft' : 3.489718808175880)
(T.set': [[Travine, "Mirginel Boons"]], "y.set'; [[Travine, "man, "Mirginel Boons"]], "map' : 0.788128024446022, "comf' : 1.0, "11ft' : 3.489718808175890)
(T.set': [[Travine, "mar, "Paul Gregott']], "y.set'; [[Travine, "man, "D.set', "man, "
```

本次实验通过 Apriori 算法按照 support, confidence, LIFT 等指标计算 出了频繁项集和他们之间的关系,对最终挖掘得到的关联规则进行分析我们 可以得知, "province"属性和"country"属性关联度极高,且 "province -> country"规则的置信度极高,与事实相符;还有"taster\_twitter\_handle"属性和 "taster\_name"也有较大的关联度,及品酒者与其拥有的twitter 账号名对应